





강화학습 2탄

AI Vision

발표자:이세훈






Q 함수



학습 전: 50스텝, 보상 -24.80

학습 후: 8스텝, 보상 99.30


→ 학습 후 에이전트는 벽을 피해 최단 경로로 목표에 도달합니다!





Q 함수

Q-Learning



state



reward


Q-table

State 1	State 2	State 3
Q	Q(1, up)	Q(2, up)
Q	Q(1, lef)	Q(4, a'))
Q	Q(3, ap)	Q(5, a'))
Q	Q(4, dn)	Q(6, an)

action

$$Q(s, a) \leftarrow Q(s, a) + \alpha [\text{reward} + \max_{a'} Q(s', a') - Q(s, a)]$$

Q-Learning (Table)





Q 함수 한계

1. 차원의 저주 (Curse of Dimensionality)

상태와 행동의 가짓수가 조금만 늘어나도 메모리가 기하급수적으로 커집니다. 예를 들어, 바둑이나 자율주행처럼 상태의 경우의 수가 무한에 가까운 환경에서는 모든 상태를 표에 담는 것이 불가능합니다

2. 연속적인 공간(Continuous Space) 적용 불가

Q러닝은 기본적으로 상태와 행동이 이산적인(Discrete) 환경에서만 작동합니다. 각도, 속도, 좌표 등 실수(Real Number)로 이루어진 연속적인 공간을 다룰 때는 적용하기 어렵습니다.

3. 새로운 상태(Unseen State)에 대한 일반화 부족

Q-테이블에 없는 새로운 상태를 마주하면 에이전트는 어떻게 행동해야 할지 알지 못합니다. 과거의 경험을 바탕으로 새로운 상황을 유추(Generalization)하는 능력이 전혀 없습니다.

4. 방대한 학습 시간



모든 상태-행동 조합에 대해 충분한 시행착오를 겪으며 표를 업데이트해야 하므로, 복잡한 문제일수록 최적의 값(Convergence)에 도달하는 데 엄청난 학습 시간이 소요됩니다.



정적인 상태 vs 동적인 상태



Q 함수 한계



현실에 있는 대부분의 데이터는 어느 추세일까




DQN

구분 	가치 기반 (Value-based)	정책 기반 (Policy-based)
핵심 개념	"이 행동을 했을 때 보상이 얼마나 될까?" (가치 학습)	"이 상황에서는 어떤 행동을 할 확률을 높여야 할까?" (정책 학습)
행동 선택 기준	가치가 가장 높은 행동을 주로 선택 (결정론적)	확률 분포에 따라 행동을 선택 (확률적)
연속적 행동 처리	어려움 (연속된 실수 값을 다루기 힘들)	매우 자연스러움 (각 행동의 확률을 연속적으로 조정 가능)
수렴성 및 효율성	샘플 효율이 높고 안정적으로 학습됨	샘플 효율이 낮고 학습이 불안정할 수 있음
대표 알고리즘	DQN, Q-Learning	REINFORCE, Policy Gradient




DQN

가치기반 (Q-Learning, DQN)



리뷰점수:
85



리뷰점수:
90




리뷰점수:
57

정책기반 (REINFORCE)



33%



33%




33%




DQN

Q 함수 학습





DQN 학습





DQN





감사합니다

Vision AI

발표자:아무개